

언어 인지

고려대학교 석준희

*ChatGPT: Optimizing
Language Models
for Dialogue*

We've trained a model called ChatGPT which interacts in a conversational way. The dialogue format makes it possible to challenge incorrect premises, and request more information. ChatGPT is a sibling model to GPT-3, which follows an instruction-based paradigm.

목차

- 언어 인지 개요
- 순환 신경망
- Attention
- Transformer
- 사전 학습 모델
- BERT
- GPT
- ChatGPT

언어 인지

언어 인지 개요



인지 (Recognition)

- 인지: 지능을 갖추기 위해 필요한 기본 요소

- 시각인지



왼쪽: 고양이
오른쪽: 개
개와 고양이가 풀밭에
앉아 있음

- 언어인지

Q: 철수는 거실에서 TV를 봅니다. 영희는
방에서 공부를 합니다. 엄마가 부엌에서 거실로
갑니다. 거실에는 모두 몇 명이 있을까요?
A: 2명



자연어처리 (NLP: Natural Language Processing)

- **자연어처리(NLP):** 언어에 관련된 다양한 업무를 인공지능을 통해 해결하는 것이 목표
- 음성을 글로 변환하는 것은 보통 독립적인 과정으로 처리 (음성인식)
- **감성분석:** 글의 분위기를 파악 (**문장 분류**)
 - 이 영화 너무 재미있어요 (긍정), 감독이 엉망이네 (부정)
- **질의응답:** 주어진 정보를 바탕으로 질문에 대답
 - 질의: 나는 서울에 사는데 내일 대전에 당일로 다녀오려고 합니다. 다음 주에 나는 어디에 있을까요?
 - 응답: 서울
- **번역:** I love you → 나는 당신을 사랑합니다.
- **요약:** 주어진 긴 글을 짧게 요약
- **작문:** 주어진 키워드 혹은 사실 관계를 바탕으로 새로운 글을 작성
 - 신문 기사의 생성
- **채팅:** 사용자와 대화
- **프로그래밍:** 인간의 언어 뿐만 아니라 컴퓨터 언어에 대한 처리



답러닝 이전의 NLP

- TF-IDF (Term-Frequency and Inverse Document Frequency)
 - 문서의 특성(단어 빈도)을 추출하여 문서를 표현
 - 단어의 순서 및 관계는 보통 무시됨
- 비정형 텍스트를 정형 데이터로 변환하여 다양한 분류 및 기계학습 문제를 해결

문장 0: I like apple

문장 1: I like banana

문장 2: long yellow banana banana

문장 3: You love fruit

	fruit	long	yellow	i	banana	apple	like	you	love
문장 0	0.00	0.00	0.00	0.29	0.00	0.69	0.29	0.00	0.00
문장 1	0.00	0.00	0.00	0.29	0.29	0.00	0.29	0.00	0.00
문장 2	0.00	0.69	0.69	0.00	0.57	0.00	0.00	0.00	0.00
문장 3	0.69	0.00	0.00	0.00	0.00	0.00	0.00	0.69	0.69



텍스트 데이터의 표현



- 각 문서(혹은 문장)은 단어 혹은 토큰으로 이루어짐
- **One-hot encoding**: 각 토큰을 서로 다른 unit vector로 표현
- 하나의 문서는 1과 0으로 이루어진 희소 행렬로 표현
- 예시: 'I love you, you love me' 의 표현
 - 4 (# of words) x 6 (text length) 행렬로 표현

	I	Love	You	You	Love	Me
I	1	0	0	0	0	0
Love	0	1	0	0	1	0
You	0	0	1	1	0	0
Me	0	0	0	0	0	1



임베딩 (Embedding)

- One-hot encoding 의 문제점
 - 너무 희소(sparse)하여 데이터 공간이 낭비, 단어 사이의 관계를 내포하지 못함
- **임베딩(Embedding)**: 고차원에서 One-hot encode된 토큰의 벡터를 저차원의 잠재공간(latent space)으로 매핑
 - N (# of tokens) $\rightarrow$ p (# of hidden features)
 - $N \times p$ 의 **임베딩 행렬**이 필요 (보통 데이터로부터 학습됨)




King	Queen	Man	Woman
0	0	1	1
0	1	0	1

King	Queen	Man	Woman
0	0	1	1
0	1	1	0



임베딩 (Embedding)

- 잠재공간(Latent space): 각 단어의 의미를 내포하는 잠재 변수(latent vector)로 이루어진 저차원의 공간





텍스트 데이터의 현대적 표현

- 하나의 문장은 잠재 공간에 매핑된 벡터의 순차(sequence)로 표현
 - 문장마다 길이가 서로 다름
- 순차적인 입력을 받을 수 있는 모델이 필요

	I	Love	You	You	Love	Me
I	1	0	0	0	0	0
Love	0	1	0	0	1	0
You	0	0	1	1	0	0
Me	0	0	0	0	0	1

	I	Love	You	You	Love	Me
H1	0	-0.5	0.5	0.5	-0.5	0.5
H2	0.5	0.5	0	0	0.5	0.5

긍정적: 1
부정적: 0




$x_1 \quad x_2 \quad x_3 \quad x_4 \quad x_5 \quad x_6 \longrightarrow y$



순환신경망 (RNN: Recurrent Neural Network)

- 순환신경망(RNN): 순차 데이터를 처리하는 신경망 모델



<https://www.datacamp.com/tutorial/tutorial-for-recurrent-neural-network>

		I	Love	You	You	Love	Me	<E>	긍정
H1	-1	0	-0.5	0.5	0.5	-0.5	0.5	1	
H2	-1	0.5	0.5	0	0	0.5	0.5	1	




딥러닝 언어 모델

• Seq2Seq 모델

- 순차 데이터를 입력으로 받아 순차 데이터를 출력으로 내는 모델
- 문장 분류 뿐만 아니라 번역, Q&A 등에도 사용될 수 있음
- 문제에 따라 다양한 형태가 존재

one to one



일반적
신경망
(순열X)

one to many






Image
Captioning

many to one




감성분석
문장분류

many to many



번역
Q&A

many to many



개체명 인식
토큰분류



딥러닝 언어 모델

• Seq2Seq 모델

- 인공지능 번역, Q&A 등에 적용
- 긴 문장에 대해서는 효과가 떨어짐
 - 이전 문장의 모든 정보가 Context라는 고정된 길이로 표현





그림 7-7 Encoder는 문장을 고정 길이 벡터로 인코딩한다.






답러닝 언어 모델

- **Attention 모델**

- 이전 RNN 노드의 정보를 다시 이용해서 최종 출력을 결정
- Attention 모듈이 어떤 정보를 얼마나 참조할지 결정






딥러닝 언어 모델

- Transformer 모델

- Attention 블록만을 이용하여 전체 데이터를 encoding/decoding
- 순서를 표현하기 위해 Positional encoding이 같이 사용







답러닝 언어 모델


Transformer 모델

- Encoder 내부에서는 self-attention 모듈을 사용
- Decoder는 Encoder의 정보를 받기 위해 일반적 attention을 사용
- Decoder는 순차적 입력의 고려를 위해 masked self-attention을 사용
 - Je를 도출하기 위해 suis를 사용할 수 없음




Large Language Model


- Pretrain + Fine-tuning: 사전 학습된 초거대 언어 모델 위에 각 NLP 문제를 해결하는 신경망을 연결하여 미세 학습 시키는 방식




(a) Sentence Pair Classification Tasks:
MNLI, QQP, QNLI, STS-B, MRPC,
RTE, SWAG



(b) Single Sentence Classification Tasks:
SST-2, CoLA



(c) Question Answering Tasks:
SQuAD v1.1




(d) Single Sentence Tagging Tasks:
CoNLL-2003 NER



Large Language Model


- Zero/One/Few-shot learning on Pre-trained Model: 거대 언어 모델 자체로 언어를 이해하고 몇 가지 예시를 제시하여 유사하게 문제를 푸는 방식





Large Language Model

- 다양한 초거대 언어 모델이 개발되고 있음
 - 인간의 두뇌는 100조개의 시냅스(매개변수에 해당)를 갖고 있음





ChatGPT의 등장

동아일보 | 국제

1초도 안돼 ‘철학 논술’ 쓴 AI챗봇… “숙제 맡길라” 美교육계 비상

뉴욕=김현수 특파원

입력 2022-12-30 03:00 | 업데이트 2023-02-17 10:56

구글·MS 등 투자한 ‘챗GPT’ 이용
美대학생 ‘흙 호러의 역설’ 과제 내
교수 “초보자엔 완벽해 보일 수준”

모르는 건 포털 검색? ‘ChatGPT’는 필요한 답만 보여줄게

이희욱 기자 +구독

f t t k s g 가*

경제

1. ‘남이
100%
출생

조선경제 > 증권·금융

챗GPT는 요술봉? 살짝만 스

챗GPT ‘묻지마 투자’ 주의

권순완 기자 오로라 기자

입력 2023.02.08 03:00

한국과 미국에서 주가 급등한
‘챗GPT 관련주’
올해 주가 상승률, 지난 6일 기준

홈 > 사회 > 사회종합

챗GPT 믿을 수 있나... 삼일절 물었더니 줄줄이 ‘오답’

강현수 | 입력 2023.02.28 18:12 | 수정 2023.03.01 13:14 | 댓글 0



본보, 챗GPT에 유관순 물었더니
‘전남순천 태생·신촌에서 처형’ 등
3초만에 역사적 사실과 다른 오답
민족대표33인 상관없는 인물 나열
출처 없고 신뢰도 낮아 ‘과신 금물’

언어 인지


순환 신경망



순환신경망 (RNN: Recurrent Neural Network)

- 순환신경망(RNN): 순차 데이터를 처리하는 신경망 모델
 - 텍스트 데이터 뿐만 아니라 일반적인 순차적 데이터를 처리
 - 시계열 데이터 분석에도 사용 (e.g. 주가 데이터, 동영상 데이터 등)
 - RNN 셀(cell)이 데이터 길이만큼 반복되어 사용되는 형태
 - 셀 모델 자체는 모든 시점에 동일하지만 입력(현재 입력 + 과거 셀의 은닉정보)에 따라 현재 셀의 은닉정보가 결정됨
 - 은닉정보(h , hidden output): 각 순차별 셀의 출력으로 최종 출력(y)과는 구별


$$h_t = \text{RNNCell}(h_{t-1}, x_t)$$





Simple RNN

- **Simple RNN** (Naïve RNN): 가장 기본적인 RNN 구조
 - 일반적으로 하나의 단일 계층 신경망을 사용
 - 하이퍼 탄젠트를 활성화함수로 사용 (경사도소멸을 완화)




$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$$



Simple RNN

- 상세 계산



은닉벡터크기 = 2

입력벡터크기 = 2

파라미터의 수 = $2 \times (2 + 2 + 1) = 10$

$$h_{t,1} = \tanh(w_{h,11}h_{t-1,1} + w_{h,12}h_{t-1,2} + w_{x,11}x_{t,1} + w_{x,12}x_{t,2} + b_1)$$

$$h_{t,2} = \tanh(w_{h,21}h_{t-1,1} + w_{h,22}h_{t-1,2} + w_{x,21}x_{t,1} + w_{x,22}x_{t,2} + b_2)$$

$$\begin{bmatrix} h_{t,1} \\ h_{t,2} \end{bmatrix} = \tanh \left(\begin{bmatrix} w_{h,11} & w_{h,12} \\ w_{h,21} & w_{h,22} \end{bmatrix} \begin{bmatrix} h_{t-1,1} \\ h_{t-1,2} \end{bmatrix} + \begin{bmatrix} w_{x,11} & w_{x,12} \\ w_{x,21} & w_{x,22} \end{bmatrix} \begin{bmatrix} x_{t,1} \\ x_{t,2} \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \end{bmatrix} \right)$$



$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$$




Simple RNN

- 최종 출력(y)은 은닉정보(h)를 이용해 다시 계산

$$y_t = \sigma(W_y h_t + b_y)$$



문장분류
마지막에서 셀에서 출력 계산




토큰분류
각 셀에서 출력 계산



Simple RNN

- RNN의 훈련: 시간을 역순으로 역전파를 진행하여 수행
 - **BPTT**: Backpropagation through time
 - 순차가 길어질 수록 네트워크가 깊어지는 효과 → 경사도 소멸




<https://dennybritz.com/posts/wildml/recurrent-neural-networks-tutorial-part-3/>

- 장기기억 (Long-term memory) 의존성/소멸의 문제
 - 순차가 길어질 수록 앞쪽 데이터가 뒤쪽으로 잘 전달되지 않음
 - 단기기억(Short-term memory)에만 결과가 의존함



LSTM (Long Short Term Memory)


- **LSTM**: RNN의 장기기억 의존성 문제를 해결하기 위해 고안
 - 장단기 기억을 선택적으로 고려할 수 있는 구조(Forget gate)를 포함
 - 은닉정보(h)와 구별되는 셀 상태(c)에 대한 변수를 추가
 - 은닉정보는 단기기억을, 셀 상태는 장기기억을 표현
 - 장점: Simple RNN에 비해 장기기억 보존에 유리
 - 단점: 구조가 복잡
 - 현재 가장 많이 사용되는 RNN 셀 구조





LSTM (Long Short Term Memory)

- 임시 셀 상태 ($\tilde{C}_t$): RNN의 은닉 정보, 이를 이용해 셀 상태와 은닉정보 출력을 계산
- **입력 게이트** (Input gate, i_t): 임시 셀 상태를 선택적으로 고려하기 위한 입력
- **망각 게이트** (Forget gate, f_t): 이전 셀 상태(C_{t-1})를 고려하는 정도에 대한 계산
- 현재 셀 상태 (C_t): 이전 셀 상태와 임시 셀 상태를 선택적으로 고려해 계산, 장기기억
- **출력 게이트** (Output gate, o_t): 은닉정보 출력을 선택적으로 계산하기 위한 모듈
- 은닉 출력 (h_t): 셀상태를 선택적으로 고려하여 계산, 단기기억



(a) Long Short-Term Memory

$$\tilde{C}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$$

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$

$$C_t = f_t \circ C_{t-1} + i_t \circ \tilde{C}_t$$


$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$$

$$h_t = o_t \circ \tanh(C_t)$$



GRU (Gate Recurrent Unit)

- **GRU:** LSTM의 복잡한 구조를 단순화
 - 은닉정보(h)와 셀 상태(c)를 통합
 - 업데이트 게이트 (z_t): 입력 게이트와 망각 게이트를 통합
 - LSTM보다 단순하지만 (훈련이 쉽지만) 성능은 유사



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$


$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$




RNN의 확장

- 다계층(Multi-layer) RNN: 심층 구조로 더 복잡한 패턴의 파악이 가능



<https://github.com/rasbt/python-machine-learning-book-3rd-edition>

- 양방향(Bidirectional) RNN: 양방향 구조로 전체 정보를 고려하는데 유리
 - 문장 전체를 보고 분류, 빈 칸 채우기 등,
 - 순차/시계열 예측에는 사용이 어려움 (미래 정보를 볼 수 없음!)




<https://www.geeksforgeeks.org/bidirectional-lstm-in-nlp/> 30



RNN을 이용한 감성 분석

- 감성분석 (Sentiment Analysis)
 - 리뷰 문장의 긍정/부정 등을 판단하는 문제



언어 인지

Attention




기본 아이디어

- 기존 Seq2Seq 언어 모델의 문제
 - 앞쪽(앞선 단어)의 정보가 제한적으로 전달됨
 - 뒤쪽의 내용에 따라 앞쪽의 정보를 선택적으로 활용하는 것이 어려움
- **Attention mechanism**
 - Bahdanau et al, ICLR, 2015에서 기본적인 아이디어가 제시
 - Vaswani et al, NIPS, 2017에서 Transformer가 제시되면 본격적으로 활용
 - 현재 시점에서 참고해야 할 앞쪽 단어를 선택적으로 연관시킬 수 있는 구조를 제안
 - 과거의 단어는 그 단어의 상태(Key)와 그 단어가 내재하는 정보(Value)로 이루어짐
 - 현재 시점 단어의 상태(Query)를 이용해 각 단어의 정보를 얼마큼 활용 (Attention Score) 해야 하는지 계산
 - 각 단어의 활용치만큼 정보(Value)를 사용하여 값을 계산

$$\begin{aligned}\text{Attention}(Q,K,V) &= \text{AttentionScore}(Q,K) \times V \\ &= \text{Attention Value}\end{aligned}$$

Attention Mechanism


- Seq2Seq 모델의에서 Attention의 활용
 - 각 RNN 셀의 hidden state를 key 와 query로 활용 -
 - value 또한 각 hidden state를 이용



Query 1:
Hidden state at
current time step




Attention Mechanism



$$a(\mathbf{q}, \mathbf{k}) = \frac{\mathbf{q}^T \mathbf{k}}{\sqrt{|\mathbf{k}|}}$$


Query 1:
Hidden state at
current time step

Attention Mechanism



$$\text{softmax}\left(\frac{\mathbf{q}^T \mathbf{k}}{\sqrt{|\mathbf{k}|}}\right)$$

Attention Mechanism




We use the attention distribution to compute a weighted average of the hidden states.

Intuitively, the resulting attention output contains information from hidden states that received high attention scores

$$\sum \text{softmax} \left(\frac{\mathbf{q}_i^T \mathbf{k}_i}{\sqrt{|\mathbf{k}_i|}} \right) \mathbf{k}_i$$

value


Attention Mechanism



Concatenate (or otherwise compose) the attention output with the current hidden state, then pass through a softmax layer to predict the next word

$$\hat{y}_1 = \text{FC} \left(\left[\sum \text{softmax} \left(\frac{\mathbf{q}_i^T \mathbf{k}_i}{\sqrt{|\mathbf{k}_i|}} \right) \mathbf{k}_i, \mathbf{k}_j \right] \right)$$

Attention Mechanism





Attention Mechanism

- 정보 Bottleneck 을 해소하는 것이 가능
 - 디코더가 직접적으로 인코더의 소스를 선택적으로 보는 것이 가능
- 경사 소멸의 효과를 줄일 수 있음
 - 멀리 떨어진 정보로 갈 수 있는 shortcut을 제공
- 모델에 대한 해석 가능성을 제공
 - Attention score는 모델이 예측하는데 이전 정보를 얼마나 보는지 수치적으로 표현
 - Attention Map

→ The
poor
don't
have
any
money

	Les	pauvres	sont	démunis
The	Dark			
poor		Dark		
don't			Dark	Dark
have			Dark	Dark
any			Dark	Dark
money			Dark	Dark



다양한 형태의 어텐션

- 다양한 형태의 어텐션이 가능

이름	스코어 함수	Defined by
<i>dot</i>	$score(s_t, h_i) = s_t^T h_i$	Luong et al. (2015)
<i>scaled dot</i>	$score(s_t, h_i) = \frac{s_t^T h_i}{\sqrt{n}}$	Vaswani et al. (2017)
<i>general</i>	$score(s_t, h_i) = s_t^T W_a h_i$ // 단, W_a 는 학습 가능한 가중치 행렬	Luong et al. (2015)
<i>concat</i>	$score(s_t, h_i) = W_a^T \tanh(W_b[s_t; h_i]), score(s_t, h_i) = W_a^T \tanh(W_b s_t + W_c h_i)$	Bahdanau et al. (2015)
<i>location - base</i>	$\alpha_t = softmax(W_a s_t)$ // α_t 산출 시에 s_t 만 사용하는 방법.	Luong et al. (2015)




언어 인지

Transformer



트랜스포머 이전의 언어 모델


- **Encoding:** 양방향 RNN 모델을 사용하여 입력 문장의 정보를 함축
- **Decoding:** 단방향 RNN 모델을 사용하여 출력 문장을 생성
- **Attention:** 문장을 생성할 때 참조해야할 정보를 Attention을 통해 결정





트랜스포머 이전의 언어 모델


- 이전에는 각 NLP 문제에 적합한 모델을 각각 훈련시켰음
 - 질의응답, 번역, 감성분석 등
- 많은 NLP 모델들이 공통적으로 입력 문장의 의미를 함축할 필요가 있음
- 각 문제를 푸는 새로운 방식을 제시하는 대신,
- 문장의 의미를 함축하고 대응문장을 제시할 수 있는 기반 블록을 제작하고자 함
- 이를 이용하여 더욱 다양한 NLP의 문제를 해결하는 것을 목적






RNN 모델의 한계

- 각 단어 사이의 거리가 멀어지면 앞쪽의 정보가 전달되지 않음




- 병렬처리가 어려워 연산 속도가 느림






Word Window

- 지역적인 문맥을 모으기 위하여 Word Window를 사용
 - 1D CNN과 비슷한 방식으로 동작



- 레이어를 거치면서 떨어져 있는 정보가 함께 취합될 수 있지만, 너무 멀리있는 것은 아직도 어려움





Too far from h_k to be considered



Word Window

- Attention 으로 해결!!
 - Encoder-decoder 사이의 attention이 아닌, 하나의 문장 내에서의 attention
 - 각 레이어에서 모든 단어의 정보를 곧바로 얻어오는 것이 가능





Self-Attention

- Attention 은 query, key, value 로 계산

$$e_{ij} = q_i^\top k_j$$

Compute **key-query** affinities

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{j'} \exp(e_{ij'})}$$

Compute attention weights from affinities (softmax)

$$\text{output}_i = \sum_j \alpha_{ij} v_j$$


Compute outputs as weighted sum of **values**

- Self-attention에서는 query, key, value가 모두 같은 문장에서 계산되고, 이들 값 또한 같은 소스로부터 계산됨
 - 구체적인 계산은 Transformer의 구현 방식과 레이어에 따라 달라짐
 - 입력 레이어: q, k, v가 같은 단어로부터 다른 encoding을 통해 생성
 - 상위 레이어: 각 이전 레이어의 출력을 동일하게 q, k, v로 사용



Position Representation

- Self-Attention은 구조상 단어의 순서가 중요하지 않음
- 단어의 순서가 뒤바뀌어도 모델의 웨이트는 변하지 않음






Position Representation

- **Position vector:** 각 단어의 위치를 표현할 수 있는 새로운 벡터를 도입

$$p_i \in \mathbb{R}^d, \text{ for } i \in \{1, 2, \dots, T\}$$

- **Sinusoidal position representation:** 다양한 주기의 sin함수를 이용하여 위치를 표현
 - 장점: 절대적인 위치가 중요하지 않고 상대적인 위치가 중요, 어느 길이의 문장도 표현이 가능
 - 단점: 학습해서 얻는 값이 아님

$$p_i = \begin{pmatrix} \sin(i/10000^{2*1/d}) \\ \cos(i/10000^{2*1/d}) \\ \vdots \\ \sin(i/10000^{2*\frac{d}{2}/d}) \\ \cos(i/10000^{2*\frac{d}{2}/d}) \end{pmatrix}$$



- **Learned absolute position representation:** 학습을 통해 표현, 하지만 일정 길이 이상의 문장에 대해서는 불가능



Position Representation

- **Position vector:** 각 단어의 위치를 표현할 수 있는 새로운 벡터를 도입

$$p_i \in \mathbb{R}^d, \text{ for } i \in \{1, 2, \dots, T\}$$

- **Sinusoidal position representation:** 다양한 주기의 sin/cos 함수를 이용하여 표현
- **Learned absolute position representation:** 학습을 통해 표현, 하지만 일정 길이 이상의 문장에 대해서는 불가능
- 참조 방법
 - 첫 번째 레이어에서만 적용
 - 일반적으로 q, k, v 에 직접 더해서 사용하지만 다른 방식 (concat)도 가능

$$v_i = \tilde{v}_i + p_i$$


$$q_i = \tilde{q}_i + p_i$$

$$k_i = \tilde{k}_i + p_i$$



Nonlinearity

- Attention score는 비선형적으로 결정되지만 attention value 자체는 결국 각 단어 정보의 선형적 결합
 - 상위 계층 또한 결국 정보의 선형적 결합이기 때문에 stack을 쌓아도 이득이 없음
- FFN을 삽입하여 해결





Nonlinearity

- 기본적인 Self-attention은 뒤쪽의 단어를 미리 참조할 수 있는 형태
- 경우에 따라 문장 뒤쪽의 단어를 사전에 참조할 수 없는 경우가 발생
 - E.g. decoder에서 문장 생성을 위해 self-attention을 사용하려는 경우
- Masked self-attention: 뒤쪽 문장에 대한 attention score를 작게 만들어 참조를 하지 않음

$$e_{ij} = \begin{cases} q_i^\top k_j, j < i \\ -\infty, j \geq i \end{cases}$$

	[START]	The	chef	who
[START]	$-\infty$	$-\infty$	$-\infty$	$-\infty$
The		$-\infty$	$-\infty$	$-\infty$
chef			$-\infty$	$-\infty$
who				$-\infty$




Self-Attention 정리

- Self-attention
 - Encoder-decoder를 블록으로 만들기 위한 기본적인 방법
- Position representation
 - Self-attention 자체에는 단어의 순서를 참고하는 기능이 없기 때문에 position vector를 학습하여 사용
- Nonlinearity
 - FFN을 중간에 삽입하여 비선형성을 제공
- Masking
 - 뒤쪽의 단어를 참조하지 못하게 하기 위한 기법

트랜스포머


- Vaswani et al, "Attention is all you need", NIPS 2017 (Google)에서 발표
 - 이 논문에서는 번역 문제에 대하여 제안
- Attention만을 이용하는 Encoder와 Decoder를 블록으로 만들어 학습





트랜스포머

- Vaswani et al, "Attention is all you need", NIPS 2017 (Google)에서 발표
- Attention만을 이용하는 Encoder와 Decoder를 블록으로 만들어 Self-supervised learning을 통해 언어의 구조 자체를 학습하는 모델





Transformer Encoder

- 기본적으로 Self-Attention을 이용하지만, 몇 가지 추가사항이 필요
- Query, Key, Value의 계산
 - 단일 입력으로부터 서로 다른 Q, K, V의 값을 계산
- Multi-head Attention
 - 동일한 레이어 내에서 서로 다른 attention을 계산
- 훈련을 돕기 위한 몇 가지 트릭
 - Residual connection
 - Layer normalization
 - Scaling dot-product
 - 모델 자체의 기능을 추가하지는 않지만 안정적이고 빠른 훈련을 가능하게 함



Encoder: Query, Key, Value의 계산

- Transformer Encoder 로의 입력

$$x_i \in \mathbb{R}^d$$

- Key, query, value를 계산하는 독립적인 matrix를 설정
- 이들 matrix는 데이터로부터 학습되는 값
 - $k_i = Kx_i$, where $K \in \mathbb{R}^{d \times d}$ is the key matrix.
 - $q_i = Qx_i$, where $Q \in \mathbb{R}^{d \times d}$ is the query matrix.
 - $v_i = Vx_i$, where $V \in \mathbb{R}^{d \times d}$ is the value matrix.
- 같은 단어로부터 파생되었지만 각각 다른 역할을 적절히 할 수 있도록 구성하는 역할을 함




Encoder: Query, Key, Value의 계산

- 행렬로 계산

$$X = [x_1; \dots; x_T] \in \mathbb{R}^{T \times d}$$

$$XK \in \mathbb{R}^{T \times d}, XQ \in \mathbb{R}^{T \times d}, XV \in \mathbb{R}^{T \times d}$$

$$\text{output} = \text{softmax}(XQ(XK)^T) \times XV$$





Encoder: Multi-head Attention

- 한 단어가 여러 개의 단어에 동시에 집중하고 싶은 경우를 고려
- 하나의 attention이 아니라 여러 개의 attention을 사용


$$Q_\ell, K_\ell, V_\ell \in \mathbb{R}^{d \times \frac{d}{h}},$$

$$\text{output}_\ell = \text{softmax}(XQ_\ell K_\ell^\top X^\top) * XV_\ell, \text{ where } \text{output}_\ell \in \mathbb{R}^{d/h}$$

$$\text{output} = Y[\text{output}_1; \dots; \text{output}_h], \text{ where } Y \in \mathbb{R}^{d \times d}$$


Single-head attention

(just the query matrix)



Multi-head attention


(just two heads here)






Encoder: Residual Connection


- 일반적인 연결




- Residual connection



- Residual은 일반 값에 비하여 smooth하고 stationary 함



[no residuals]



[residuals]



Encoder: Layer Normalization

- 모델의 훈련을 안정화하고 가속화하는 일반적인 기법
- 레이어에서 다음 레이어로 전달되는 입력을 다시 scale 하여 안정적인 훈련을 가능하게 함

$$\text{output} = \frac{x - \mu}{\sqrt{\sigma} + \epsilon} * \gamma + \beta$$

Normalize by scalar mean and variance

Modulate by learned elementwise gain and bias

$$x \in \mathbb{R}^d$$

$$\mu = \sum_{j=1}^d x_j$$

$$\sigma = \sqrt{\frac{1}{d} \sum_{j=1}^d (x_j - \mu)^2}$$

$$\gamma \in \mathbb{R}^d$$


$$\beta \in \mathbb{R}^d$$

학습 파라미터



Encoder 정리

- Encoder 정리






Decoder 구조

- Decoder 구조
 - Masked self-attention (Decoder only)
 - Cross-attention (Encoder-decoder)

Looking back at the whole model,
zooming in on a Decoder block:





Decoder: Cross-attention

- Decoder cross-attention에서 query, key, value의 계산


Let $h_1, \dots, h_T$ be **output** vectors **from** the Transformer **encoder**

Let $z_1, \dots, z_T$ be input vectors from the Transformer **decoder**, $z_i \in \mathbb{R}^d$

$$k_i = K h_i$$

$$v_i = V h_i$$

$$q_i = Q z_i$$



- 앞선 계산과 마찬가지로 Multi-head attention, scaled dot-product 등을 적용하는 것이 가능



- Attention is all you need 논문에서는 기계번역 문제에 Transformer를 적용

5.1 Training Data and Batching

We trained on the standard WMT 2014 English-German dataset consisting of about 4.5 million sentence pairs. Sentences were encoded using byte-pair encoding [3], which has a shared source-target vocabulary of about 37000 tokens. For English-French, we used the significantly larger WMT 2014 English-French dataset consisting of 36M sentences and split tokens into a 32000 word-piece vocabulary [38]. Sentence pairs were batched together by approximate sequence length. Each training batch contained a set of sentence pairs containing approximately 25000 source tokens and 25000 target tokens.

5.2 Hardware and Schedule

We trained our models on one machine with 8 NVIDIA P100 GPUs. For our base models using the hyperparameters described throughout the paper, each training step took about 0.4 seconds. We trained the base models for a total of 100,000 steps or 12 hours. For our big models,(described on the bottom line of table 3), step time was 1.0 seconds. The big models were trained for 300,000 steps (3.5 days).

기계 번역 성능

- 이전 결과에 비해 우수한 성능과 낮은 계산량

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest2014 tests at a fraction of the training cost.

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	41.29	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	$3.3 \cdot 10^{18}$	
Transformer (big)	28.4	41.8	$2.3 \cdot 10^{19}$	

언어 인지

사전학습 모델



Subword Model

- Finite vocabulary assumption
 - 이전 NLP(>10년전)에서는 훈련 데이터 셋에서 수 만개의 단어에 대한 사전을 구축하여 사용
 - 테스트 셋을 이용한 평가 단계에서 새로운 단어나 오타 등은 "알 수 없는 단어"로 매핑되어 사용
 - 이러한 단어 중 인간은 인지 가능한 것이 대부분
- Infinite vocabulary in the real world
 - 실생활에서는 무한히 많은 단어를 만들어 사용하는 것이 가능
 - 문맥, 중의적 표현 등으로 훨씬 복잡한 단어 체계를 갖추고 있음

	word		vocab mapping	embedding
Common words	hat	→	pizza (index)	
	learn	→	tasty (index)	
Variations	taaaaasty	→	UNK (index)	
misspellings	laern	→	UNK (index)	
novel items	Transformerify	→	UNK (index)	



Subword Model



- Subword model을 통해
 - 각 단어는 많이 사용되는 부분단어(token)로 분리되고
 - 특수한 단어는 의미를 갖는 부분단어로 분리될 가능성이 높고,
 - 최악의 경우 각 캐릭터로 분리됨

	word		vocab mapping	embedding
Common words	hat	→	hat	
	learn	→	learn	
Variations	taaaaasty	→	taa## aaa## sty	  
misspellings	laern	→	la## ern##	 
novel items	Transformerify	→	Transformer## ify	 



토큰 임베딩 (Token Embedding)

- One-hot encoding 의 문제점
 - 너무 희소(sparse)하여 데이터 공간이 낭비, 단어 사이의 관계를 내포하지 못함
- **임베딩(Embedding)**: 고차원에서 One-hot encode된 토큰의 벡터를 저차원의 잠재공간(latent space)으로 매핑
 - N (# of tokens) $\rightarrow$ p (# of hidden features)
 - $N \times p$ 의 **임베딩 행렬**이 필요 (보통 데이터로부터 학습됨)



King	Queen	Man	Woman
0	0	1	1
0	1	0	1


King	Queen	Man	Woman
0	0	1	1
0	1	1	0



토큰 임베딩 (Token Embedding)

- Word2Vec
 - 중심단어와 주변 단어 사이의 관계를 학습하여 단어를 임베딩


The fat cat sat on the mat






토큰 임베딩 (Token Embedding)

- 일반적인 NLP 모델에서 워드임베딩 부분은 학습모델과 같이 훈련됨




- Word2Vec과 같은 워드 임베딩은 독립적으로 훈련이 가능
- 임베딩을 사전학습하고 이를 이용해 Transformer나 다른 NLP 문제에 적용하는 것이 가능





전체 모델에 대한 사전학습


- 전체 모델을 사전학습하는 것도 가능



- 문장 재구성을 통해 사전 학습
 - 인접 단어의 확률을 학습

$$p_{\theta}(w_t | w_{1:t-1})$$

The woman walked across the street,
checking for traffic over ____ shoulder.






전체 모델에 대한 사전학습

- 현대의 NLP 모델은 전체 모델에 대한 사전학습 모델을 사용
- Pretraining
 - 대규모 데이터에 일반적인 언어 사이의 관계를 학습
 - 최종적인 모델의 훈련에서 좋은 초기값을 제공
- Finetuning
 - 소규모 데이터에서 원하는 작업에 대한 학습


Step 1: Pretrain (on language modeling)

Lots of text; learn general things!



Step 2: Finetune (on your task)


Not many labels; adapt to the task!






사전 학습 모델의 종류

- 세 가지 종류의 사전학습 모델




Encoders

- Bidirectional, 뒤쪽의 단어를 참조 가능
- 어떻게 사전훈련시키고 이용해야 하나?



**Encoder-
Decoders**

- 역할 배분의 문제
- 사전학습 시키는 가장 좋은 방법은?




Decoders

- 일반적인 NLP 모델의 구조
- 새로운 문장의 생성에는 좋지만 단어사이의 관계를 잘 파악할지는 의문



Pretrained Encoder Model

- 양방향 참조가 가능한 모델로 단어 사이의 관계 학습에 용이
- 뒤쪽 단어를 학습하기 때문에 일반적인 방식으로 훈련이 어려움
- Masked Language Model
 - 일부 단어를 masking하여 입력을 만들고 해당 단어를 예측하도록 모델을 학습
 - 생성시에는 마지막 단어를 masking 처리



- **BERT: Bidirectional Encoder Representations from Transformers**, Devlin 2018 (Google)



Pretrained Encoder-Decoder Model

- 양방향 참조가 가능한 encoder와 생성하는 decoder의 양쪽 이용이 가능
- 어떻게 잘 훈련할 것이지가 관건
- Denoising corrupted spanning
 - 기본적으로 masking 방식과 유사하나 여러 단어를 동시에 masking해서 예측하도록 학습

Original text

Thank you ~~for inviting~~ me to your party ~~last~~ week.

Inputs

Thank you <X> me to your party <Y> week.

Targets


<X> for inviting <Y> last <Z>

- **T5: Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer**, Raffell, 2020 (Google)



Pretrained Decoder Model

- 기본적인 언어모델과 유사한 형태의 모델
- 이전 단어에 기초해 다음 단어를 예측하는 것을 학습




- **GPT: Improving Language Understanding by Generative Pre-Training**, Radford, 2018 (OpenAI)

거대 언어 모델

- BERT, T5, GPT 등을 포함하여 다양한 초거대 언어 모델이 개발되었음

Model	Size (# Parameters)	Training Tokens
LaMDA (Thoppilan et al., 2022)	137 Billion	168 Billion
GPT-3 (Brown et al., 2020)	175 Billion	300 Billion
Jurassic (Lieber et al., 2021)	178 Billion	300 Billion
Gopher (Rae et al., 2021)	280 Billion	300 Billion
MT-NLG 530B (Smith et al., 2022)	530 Billion	270 Billion
<i>Chinchilla</i>	70 Billion	1.4 Trillion



언어 인지

BERT


- BERT: Bidirectional Encoder Representations from Transformers
 - 2019년 구글에서 발표한 양방향 인코더 기반 언어모델
 - Masking 방식으로 사전학습을 진행하고, 각 세부 문제에 따라 fine-tuning 하는 방식으로 동작

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Jacob Devlin Ming-Wei Chang Kenton Lee Kristina Toutanova

Google AI Language

{jacobdevlin, mingweichang, kentonl, kristout}@google.com



입력 구조

- Token Embeddings: subword 기반 WordPiece 사용 (30,000 token)
 - [CLS]: 문장의 시작을 표시하고 나중에 classification을 위해 사용
 - [SEP]: 문장과 문장을 구별하는 특수 token
- Segment Embeddings: 두 문장을 구별 (0과 1을 사용)
- Position Embeddings: 주기함수를 이용하여 표현

Input	[CLS]	my	dog	is	cute	[SEP]	he	likes	play	##ing	[SEP]
Token Embeddings	$E_{[CLS]}$	E_{my}	E_{dog}	E_{is}	E_{cute}	$E_{[SEP]}$	E_{he}	E_{likes}	E_{play}	$E_{##ing}$	$E_{[SEP]}$
	+	+	+	+	+	+	+	+	+	+	+
Segment Embeddings	E_A	E_A	E_A	E_A	E_A	E_A	E_B	E_B	E_B	E_B	E_B
	+	+	+	+	+	+	+	+	+	+	+
Position Embeddings	E_0	E_1	E_2	E_3	E_4	E_5	E_6	E_7	E_8	E_9	E_{10}

모델 구조

- Self-attention을 이용한 transformer 모델
 - BERT_base: 12 layers, 768 hidden space dimension, 12 heads, in total 110M parameters
 - BERT_larage: 24 layers, 1024 hidden space dimension, 16 heads, in total 340M parameters







Figure 1: The Transformer - model architecture.



모델 훈련


- Task #1: Masked LM
 - 입력 문장에서 한 토큰을 [MASK] 토큰으로 대체하고 원래 토큰을 예측하도록 훈련
 - 전체 토큰의 15%를 mask 하여 사용





모델 훈련

- Task #2: Next Sentence Prediction
 - 두 문장이 이어지는 문장인지 아닌지를 맞추도록 학습
 - 50:50의 비율로 실제로 이어지는 문장과 랜덤한 문장을 입력으로 제공



Input = [CLS] the man went to [MASK] store [SEP]

he bought a gallon [MASK] milk [SEP]

Label = IsNext

Input = [CLS] the man [MASK] to the store [SEP]

penguin [MASK] are flight ##less birds [SEP]

Label = NotNext



모델 훈련

- 훈련데이터
 - BooksCropus (800M words)
 - English Wikipedia (2,500M words)
- Trained on 64 TPUs for 4 days

Fine-tuning

- NLP task과 데이터베이스

과제	벤치마크	예제	
감정 분석 Sentiment Analysis	SST, IMDB, NSMC	입력	문장: 신만이 이 영화를 용서할수 있다
		출력	긍정 · 부정
유사도 예측 Similarity Prediction	STS, MRPC, QQP, PAWS-X	입력	문장1: 파이썬과 자바 중 뭐부터 배워야 하나요? 문장2: Java나 Python 중 하나를 배워야 한다면, 뭐부터 시작해야 할까요?
		출력	유사 · 비유사
자연어 추론 Natural Language Inference	SNLI, MNLI, XNLI, aNLI	입력	전제: 회색 개가 숲에서 쓰러진 나무를 핥고 있다. 가설: 개가 밖에 있다.
		출력	참 · 거짓 · 모름
언어적 용인 가능성 Linguistic Acceptability	CoLA	입력	문장: 그는 한 번도 프랑스에 갔다.
		출력	가능 · 불가능
기계 독해 Reading Comprehension	SQuAD, RACE, MS MARCO, KorQuAD	입력	지문: 시카고 대학의 학자들은 경제학, 사회학, 법학 분석, 문학 비평, 신학, 행동주의 정치학 등 다양한 학문 발전에 중요한 역할을 담당해왔다. [...] 이 대학은 미국 최대 대학 출판사인 시카고 대학 프레스(University Press of Chicago Press)의 본거지이기도 하다. 오는 2020년 완공될 버락 오바마 대통령 센터에는 오바마 대통령 도서관과 오바마 재단 사무소가 세워질 예정이다. 질문: 버락 오바마 대통령 센터의 완공 예정연도는?
		출력	2020년
의도 분류 Intent Classification	ATIS, SNIPS, AskUbuntu	입력	질문: 현재 위치 주변에 있는 맛집 두 곳만 알려줘
		출력	장소 검색 (식당, 가까운, 평점 좋은, 2)



Bechmark 성능

- 많은 벤치마크 데이터 베이스에서 SOTA 달성
- **QQP**: Quora Question Pairs (detect paraphrase questions)
- **QNLI**: natural language inference over question answering data
- **SST-2**: sentiment analysis
- **CoLA**: corpus of linguistic acceptability (detect whether sentences are grammatical.)
- **STS-B**: semantic textual similarity
- **MRPC**: microsoft paraphrase corpus
- **RTE**: a small natural language inference corpus


System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.8	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	87.4	91.3	45.4	80.0	82.3	56.0	75.1
BERT _{BASE}	84.6/83.4	71.2	90.5	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	92.7	94.9	60.5	86.5	89.3	70.1	82.1

- 한계점
 - 인코더 기반의 모델이기 때문에 문장 생성에는 좋지 못함




Bechmark 성능

- RoBERTa: 좀 더 긴 문장에 BERT를 학습, NSP가 없음
- SpanBERT: 연속된 단어를 동시에 masking하여 좀 더 어려운 문제를 만들고, 이를 통해 강력한 pretraining을 제공



RoBERTa



SpanBERT

언어 인지

GPT



GPT: Generative Pretrained Transformer

- “Improving Language Understanding by Generative Pre-Training”, Radford et al, 2018
 - “GPT”라는 단어는 원 논문에 등장하지 않음!!!
- Decoder 기반의 사전학습된 트랜스포머
- 12개의 계층과 117M의 파라미터
- BookCorpus에서 학습 (7,000개의 서적)
 - 연속된 맥락의 긴 문장을 학습

Improving Language Understanding by Generative Pre-Training

Alec Radford
OpenAI
alec@openai.com

Karthik Narasimhan
OpenAI
karthikn@openai.com


Tim Salimans
OpenAI
tim@openai.com

Ilya Sutskever
OpenAI
ilyasu@openai.com



모델 구조와 사전 학습

- 일반적인 decoder transformer로 12개의 레이어
- 768-dimension hidden state, 3,072-dimension feedforward layers
- Causal language (Autoregressive) model 로 사전 훈련



$$h_0 = UW_e + W_p$$

$$h_l = \text{transformer_block}(h_{l-1}) \forall i \in [1, n]$$

$$P(u) = \text{softmax}(h_n W_e^T)$$

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

GPT

어제 카페 갔었어 거기 사람 많더라




BERT

어제 카페 갔었어 사람 많더라

Fine-tuning

- 분류 작업에 주로 적용 (GPT-1은 생성 작업에 적용되지 않음)
- <delim>으로 구별되는 두 문장을 입력하고, 마지막 <extract> 토큰의 출력으로 문장 사이의 관계를 분류

Premise: *The man is in the doorway*
 Hypothesis: *The person is near the door* } **entailment**





벤치마크 성능

- Natural language inference

Method	MNLI-m	MNLI-mm	SNLI	SciTail	QNLI	RTE
ESIM + ELMo [44] (5x)	-	-	<u>89.3</u>	-	-	-
CAFE [58] (5x)	80.2	79.0	<u>89.3</u>	-	-	-
Stochastic Answer Network [35] (3x)	<u>80.6</u>	<u>80.1</u>	-	-	-	-
CAFE [58]	78.7	77.9	88.5	<u>83.3</u>		
GenSen [64]	71.4	71.3	-	-	<u>82.3</u>	59.2
Multi-task BiLSTM + Attn [64]	72.2	72.1	-	-	82.1	61.7
Finetuned Transformer LM (ours)	82.1	81.4	89.9	88.3	88.1	56.0

- Q&A

Method	Story Cloze	RACE-m	RACE-h	RACE
val-LS-skip [55]	76.5	-	-	-
Hidden Coherence Model [7]	<u>77.6</u>	-	-	-
Dynamic Fusion Net [67] (9x)	-	55.6	49.4	51.2
BiAttention MRU [59] (9x)	-	<u>60.2</u>	<u>50.3</u>	<u>53.3</u>
Finetuned Transformer LM (ours)	86.5	62.9	57.4	59.0

- “Language Models are Unsupervised Multitask Learners”, Radford et al, 2018

Language Models are Unsupervised Multitask Learners

Alec Radford^{* 1} Jeffrey Wu^{* 1} Rewon Child¹ David Luan¹ Dario Amodei^{** 1} Ilya Sutskever^{** 1}

- 현재의 NLP 모델
 - Single task experts: pretrained LM (general) + fine-tuning (specific)
 - 인간은 특별한 훈련없이 다양한 문제를 푸는 것이 가능
- Multi-task model
 - 지도학습 기반의 fine-tuning 없이 (zero-shot learning) 혹은 매우 적게 학습하여 (few-shot learning) 문제를 해결
 - 비지도학습 만으로 문제를 해결할 수 있는 모델을 개발

GPT-2

- GPT-1 vs. GPT-2
 - GPT-2는 특별한 fine-tuning 없이 NLP 문제를 해결할 수 있는지 확인
 - 기본적으로 GPT-1과 같은 모델 구조를 따르지만, 더 모델이 커졌고 더 많은 데이터 셋을 사용

	Parameters	Layers	d_{model}
GPT-1	117M	12	768
BERT_large	345M	24	1024
	762M	36	1280
GPT-2	1542M	48	1600

- 모델의 학습
 - GPT-1과 유사한 Auto-regressive 방식으로 학습
 - Web에서 모은 40GByte의 text (8M texts)



벤치마크 성능

- 빈칸 채우기에 대해서는 Zero-shot으로 SOTA 달성

Language Models are Unsupervised Multitask Learners

	LAMBADA (PPL)	LAMBADA (ACC)	CBT-CN (ACC)	CBT-NE (ACC)	WikiText2 (PPL)	PTB (PPL)	enwik8 (BPB)	text8 (BPC)	WikiText103 (PPL)	1BW (PPL)
SOTA	99.8	59.23	85.7	82.3	39.14	46.54	0.99	1.08	18.3	21.8
117M	35.13	45.99	87.65	83.4	29.41	65.85	1.16	1.17	37.50	75.20
345M	15.60	55.48	92.35	87.1	22.76	47.33	1.01	1.06	26.37	55.72
762M	10.87	60.12	93.45	88.0	19.93	40.31	0.97	1.02	22.05	44.575
1542M	8.63	63.24	93.30	89.05	18.34	35.76	0.93	0.98	17.48	42.16

- CBT (Children's Book Test) : 10개의 선택지 중 빈 칸에 들어갈 단어 찾기
- LAMBADA: 문자의 마지막 단어 예측, 사람의 경우 50단어 이상이 필요
- Acc: Accuracy
- PPL: Perplexity, 문장이 자연스러울 확률의 역수
 - 어떤 언어모델로 실제 인간이 작성한 문장에 대해 PPL을 구했을 때, 그것이 좋은 모델이라면 해당 문장을 자연스럽다고 판단할 것이고 그러면 PPL이 낮아짐.



벤치마크 성능

- 좀 더 일반적인 task에 대해서는 SOTA를 달성하지 못함
 - 문장 요약
 - 번역
 - Q&A
- 하지만 각 작업에 대한 supervised learning 없이 이 정도 성능을 달성한 것에 의의


GPT-3

- 기본적으로는 이전 GPT와 유사한 구조, 하지만 더 커졌음

	Model Name	n_{params}	n_{layers}	d_{model}	n_{heads}	d_{head}	Batch Size	Learning Rate
GPT-1	GPT-3 Small	125M	12	768	12	64	0.5M	6.0×10^{-4}
	GPT-3 Medium	350M	24	1024	16	64	0.5M	3.0×10^{-4}
	GPT-3 Large	760M	24	1536	16	96	0.5M	2.5×10^{-4}
GPT-2	GPT-3 XL	1.3B	24	2048	24	128	1M	2.0×10^{-4}
	GPT-3 2.7B	2.7B	32	2560	32	80	1M	1.6×10^{-4}
	GPT-3 6.7B	6.7B	32	4096	32	128	2M	1.2×10^{-4}
	GPT-3 13B	13.0B	40	5140	40	128	2M	1.0×10^{-4}
	GPT-3 175B or "GPT-3"	175.0B	96	12288	96	128	3.2M	0.6×10^{-4}

- In-context learning:** 몇 개의 예시만 주면 그 패턴을 보고 task를 해결

Learning via SGD during unsupervised pre-training



The three settings we explore for in-context learning

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 cheese => ..... ← prompt
```

One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← example
3 cheese => ..... ← prompt
```

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← examples
3 peppermint => menthe poivrée ←
4 plush girafe => girafe peluche ←
5 cheese => ..... ← prompt
```

Traditional fine-tuning (not used for GPT-3)

Fine-tuning


The model is trained via repeated gradient updates using a large corpus of example tasks.





성능의 변화

- 약간의 예제는 성능을 크게 향상시킬 수 있음





성능 비교

- Language modeling: SOTA 달성

Setting	PTB
SOTA (Zero-Shot)	35.8 ^a
GPT-3 Zero-Shot	20.5

- LAMBADA: 단순한 문제에는 SOTA, 복잡한 문제는 아직 SOTA에 못 미침

Setting	LAMBADA (acc)	LAMBADA (ppl)	StoryCloze (acc)	HellaSwag (acc)
SOTA	68.0 ^a	8.63 ^b	91.8^c	85.6^d
GPT-3 Zero-Shot	76.2	3.00	83.2	78.9
GPT-3 One-Shot	72.5	3.35	84.7	78.1
GPT-3 Few-Shot	86.4	1.92	87.7	79.3



성능 비교

- Open-domain Closed-book Q&A
 - 일반적인 영역에 대하여 외부 정보의 참조없이 질문에 답하는 능력

Setting	NaturalQS	WebQS	TriviaQA
RAG (Fine-tuned, Open-Domain) [LPP ⁺ 20]	44.5	45.5	68.0
T5-11B+SSM (Fine-tuned, Closed-Book) [RRS20]	36.6	44.7	60.5
T5-11B (Fine-tuned, Closed-Book)	34.5	37.4	50.1
GPT-3 Zero-Shot	14.6	14.4	64.3
GPT-3 One-Shot	23.0	25.3	68.0
GPT-3 Few-Shot	29.9	41.5	71.2

Question: what color was john wilkes booth's hair

Wikipedia Page: John_Wilkes_Booth

Long answer: Some critics called Booth “the handsomest man in America” and a “natural genius”, and noted his having an “astounding memory”; others were mixed in their estimation of his acting. He stood 5 feet 8 inches (1.73 m) tall, had jet-black hair , and was lean and athletic. Noted Civil War reporter George Alfred Townsend described him as a “muscular, perfect man” with “curling hair, like a Corinthian capital”.

Short answer: jet-black



성능 비교

- 번역: Supervised 에는 못 미치지만 unsupervised는 넘은 성능

Setting	En→Fr	Fr→En	En→De	De→En	En→Ro	Ro→En
SOTA (Supervised)	45.6^a	35.0 ^b	41.2^c	40.2 ^d	38.5^e	39.9^e
XLM [LC19]	33.4	33.3	26.4	34.3	33.3	31.8
MASS [STQ ⁺ 19]	<u>37.5</u>	34.9	28.3	35.2	<u>35.2</u>	33.1
mBART [LGG ⁺ 20]	-	-	<u>29.8</u>	34.0	<u>35.0</u>	30.5
GPT-3 Zero-Shot	25.2	21.2	24.6	27.2	14.1	19.9
GPT-3 One-Shot	28.3	33.7	26.2	30.4	20.6	38.6
GPT-3 Few-Shot	32.6	<u>39.2</u>	29.7	<u>40.6</u>	21.0	<u>39.5</u>

- 대명사 지칭의 문제

Setting	Winograd	Winogrande (XL)
Fine-tuned SOTA	90.1^a	84.6^b
GPT-3 Zero-Shot	88.3*	70.2
GPT-3 One-Shot	89.7*	73.2
GPT-3 Few-Shot	88.6*	77.7



성능 비교

- Common Sense Reasoning
 - PIQA: PhysicalQA, ARC: Science QA from the 3rd~9th grade

Setting	PIQA	ARC (Easy)	ARC (Challenge)	OpenBookQA
Fine-tuned SOTA	79.4	92.0 [KKS ⁺ 20]	78.5 [KKS ⁺ 20]	87.2 [KKS ⁺ 20]
GPT-3 Zero-Shot	80.5 *	68.8	51.4	57.6
GPT-3 One-Shot	80.5 *	71.2	53.2	58.8
GPT-3 Few-Shot	82.8 *	70.1	51.5	65.4

- Reading Comprehension



Setting	CoQA	DROP	QuAC	SQuADv2	RACE-h	RACE-m
Fine-tuned SOTA	90.7 ^a	89.1 ^b	74.4 ^c	93.0 ^d	90.0 ^e	93.1 ^e
GPT-3 Zero-Shot	81.5	23.6	41.5	59.5	45.5	58.4
GPT-3 One-Shot	84.0	34.3	43.3	65.4	45.9	57.4
GPT-3 Few-Shot	85.0	36.5	44.3	69.8	46.8	58.1

성능 비교

- SuperGLUE: NLP 모델의 전반적인 성능을 측정하기 위해 모아 놓은 셋

	SuperGLUE Average	BoolQ Accuracy	CB Accuracy	CB F1	COPA Accuracy	RTE Accuracy
Fine-tuned SOTA	89.0	91.0	96.9	93.9	94.8	92.5
Fine-tuned BERT-Large	69.0	77.4	83.6	75.7	70.6	71.7
GPT-3 Few-Shot	71.8	76.4	75.6	52.0	92.0	69.0


	WiC Accuracy	WSC Accuracy	MultiRC Accuracy	MultiRC F1a	ReCoRD Accuracy	ReCoRD F1
Fine-tuned SOTA	76.1	93.8	62.3	88.2	92.5	93.3
Fine-tuned BERT-Large	69.6	64.6	24.1	70.0	71.3	72.0
GPT-3 Few-Shot	49.4	80.1	30.5	75.4	90.2	91.1





성능 비교

- NLI: 두 문장 사이의 관계 파악
 - 상당히 성능이 떨어짐





성능 비교

- 사칙연산 (+, -, *)

Setting	2D+	2D-	3D+	3D-	4D+	4D-	5D+	5D-	2Dx	1DC
GPT-3 Zero-shot	76.9	58.0	34.2	48.3	4.0	7.5	0.7	0.8	19.8	9.8
GPT-3 One-shot	99.6	86.4	65.5	78.7	14.0	14.0	3.5	3.8	27.4	14.3
GPT-3 Few-shot	100.0	98.9	80.4	94.2	25.5	26.8	9.3	9.9	29.2	21.3

- Word scrambling and manipulation


Setting	CL	A1	A2	RI	RW
GPT-3 Zero-shot	3.66	2.28	8.91	8.26	0.09
GPT-3 One-shot	21.7	8.62	25.9	45.4	0.48
GPT-3 Few-shot	37.9	15.1	39.7	67.2	0.44

- **Cycle letters in word (CL)** – The model is given a word with its letters cycled, then the “=” symbol, and is expected to generate the original word. For example, it might be given “lyinevitab” and should output “inevitably”.
- **Anagrams of all but first and last characters (A1)** – The model is given a word where every letter except the first and last have been scrambled randomly, and must output the original word. Example: criroptuon = corruption.
- **Anagrams of all but first and last 2 characters (A2)** – The model is given a word where every letter except the first 2 and last 2 have been scrambled randomly, and must recover the original word. Example: opoepnnt → opponent.
- **Random insertion in word (RI)** – A random punctuation or space character is inserted between each letter of a word, and the model must output the original word. Example: s.u!c/c!e.s s i/o/n = succession.
- **Reversed words (RW)** – The model is given a word spelled backwards, and must output the original word. Example: stcejbo → objects.



성능 비교

- SAT Analogies
 - Example: "audacious is to boldness as (a) sanctimonious is to hypocrisy, (b) anonymous is to identity, (c) remorseful is to misdeed, (d) deleterious is to result, (e) impressionable is to temptation"



성능 비교

- News article 생성
 - 짧은 뉴스(200단어 정도)를 생성하여 사람이 쓴 것인지 AI가 쓴 것인지 사람들에게 질의하여 AI가 쓴 것을 얼마나 잘 찾는지 확인

	Mean accuracy	95% Confidence Interval (low, hi)	<i>t</i> compared to control (<i>p</i> -value)	"I don't know" assignments
Control (deliberately bad model)	86%	83%–90%	-	3.6 %
GPT-3 Small	76%	72%–80%	3.9 (2e-4)	4.9%
GPT-3 Medium	61%	58%–65%	10.3 (7e-21)	6.0%
GPT-3 Large	68%	64%–72%	7.3 (3e-11)	8.7%
GPT-3 XL	62%	59%–65%	10.7 (1e-19)	7.5%
GPT-3 2.7B	62%	58%–65%	10.4 (5e-19)	7.1%
GPT-3 6.7B	60%	56%–63%	11.2 (3e-21)	6.2%
GPT-3 13B	55%	52%–58%	15.3 (1e-32)	7.1%
GPT-3 175B	52%	49%–54%	16.9 (1e-34)	7.8%

Title: United Methodists Agree to Historic Split
 Subtitle: Those who oppose gay marriage will form their own denomination
 Article: After two days of intense debate, the United Methodist Church has agreed to a historic split - one that is expected to end in the creation of a new denomination, one that will be "theologically and socially conservative," according to The Washington Post. The majority of delegates attending the church's annual General Conference in May voted to strengthen a ban on the ordination of LGBTQ clergy and to write new rules that will "discipline" clergy who officiate at same-sex weddings. But those who opposed these measures have a new plan: They say they will form a separate denomination by 2020, calling their church the Christian Methodist denomination.



성능 비교

- Learning new words
 - 새로운 단어의 정의를 주고 이를 이용해 문장을 쓰는 능력

A "whatpu" is a small, furry animal native to Tanzania. An example of a sentence that uses the word whatpu is:

We were traveling in Africa and we saw these very cute whatpus.

To do a "farduddle" means to jump up and down really fast. An example of a sentence that uses the word farduddle is:

One day when I was playing tag with my little sister, she got really excited and she started doing these crazy farduddles.

A "yalubalu" is a type of vegetable that looks like a big pumpkin. An example of a sentence that uses the word yalubalu is:

I was on a trip to Africa and I tried this yalubalu vegetable that was grown in a garden there. It was delicious.

A "Burringo" is a car with very fast acceleration. An example of a sentence that uses the word Burringo is:

In our garage we have a Burringo that my father drives to work every day.

A "Gigamuru" is a type of Japanese musical instrument. An example of a sentence that uses the word Gigamuru is:

I have a Gigamuru that my uncle gave me as a gift. I love to play it at home.

To "screeg" something is to swing a sword at it. An example of a sentence that uses the word screeg is:

We screeghed at each other for several minutes and then we went outside and ate ice cream.



성능 비교

- 영어 교정: 좋은 형태의 문장으로 바꾸어주는 능력

Poor English input: I eated the purple berries.

Good English output: I ate the purple berries.

Poor English input: Thank you for picking me as your designer. I'd appreciate it.

Good English output: Thank you for choosing me as your designer. I appreciate it.

Poor English input: The mentioned changes have done. or I did the alteration that you requested. or I changed things you wanted and did the modifications.

Good English output: The requested changes have been made. or I made the alteration that you requested. or I changed things you wanted and made the modifications.

Poor English input: I'd be more than happy to work with you in another project.

Good English output: I'd be more than happy to work with you on another project.

Poor English input: Please provide me with a short brief of the design you're looking for and that'd be nice if you could share some examples or project you did before.

Good English output: Please provide me with a brief description of the design you're looking for and that would be nice if you could share some examples or projects you have done before.

Poor English input: The patient was died.

Good English output: The patient died.

Poor English input: We think that Leslie likes ourselves.

Good English output: We think that Leslie likes us.



GPT 요약

- 기본적으로 디코더 기반의 트랜스포머 모델
- 더 강력한 모델을 만들기 위해 더 큰 모델을 더 많은 데이터에 학습
- Zero/One/Few-shot learning: fine-tuning 없이 몇 가지 예시를 제시하고 그 예시에 따라 과제를 수행하는 방식을 목표

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

언어 인지

ChatGPT



ChatGPT의 등장

동아일보 | 국제

1초도 안돼 ‘철학 논술’ 쓴 AI챗봇… “숙제 맡길라” 美교육계 비상

뉴욕=김현수 특파원

입력 2022-12-30 03:00 | 업데이트 2023-02-17 10:56

구글·MS 등 투자한 ‘챗GPT’ 이용
美대학생 ‘흙 호러의 역설’ 과제 내
교수 “초보자엔 완벽해 보일 수준”

모르는 건 포털 검색? ‘ChatGPT’는 필요한 답만 보여줄게

이희욱 기자 +구독

f t t k s g 가*

경제

1. ‘남이
100%
출생

조선경제 > 증권·금융

챗GPT는 요술봉? 살짝만 스

챗GPT ‘묻지마 투자’ 주의

권순완 기자 오로라 기자

입력 2023.02.08 03:00

한국과 미국에서 주가 급등한
‘챗GPT 관련주’
올해 주가 상승률, 지난 6일 기준

홈 > 사회 > 사회종합

챗GPT 믿을 수 있나... 삼일절 물었더니 줄줄이 ‘오답’

강현수 | 입력 2023.02.28 18:12 | 수정 2023.03.01 13:14 | 댓글 0



본보, 챗GPT에 유관순 물었더니
‘전남순천 태생·신촌에서 처형’ 등
3초만에 역사적 사실과 다른 오답
민족대표33인 상관없는 인물 나열
출처 없고 신뢰도 낮아 ‘과신 금물’



ChatGPT의 등장

- **ChatGPT:** 초거대 언어 모델을 기반으로 하여 대화의 기능을 주로 학습한 인공지능
 - 기존의 챗봇과는 다르게 질의응답, 작문, 번역, 요약 등의 기능을 내포하고 있는 것으로 생각됨
 - 수 만개의 질의-응답 데이터에서 학습되었고, 인공지능의 답변을 평가함으로써 추가로 학습됨

다른
응용 AI

ChatGPT

수 만개의
질의-응답
데이터로 학습

GPT

사전에 학습된 언어 모델

570억 개의
수집하기 쉬운
데이터로 학습



ChatGPT에 사용된 핵심 기술

- Zero-Shot (ZS) and Few-Shot (FS) In-Context Learning
- Instruction finetuning
- Reinforcement Learning from Human Feedback (RLHF)



Zero/Few-Shot In-Context Learning

- GPT 연구를 통해 생성 모델은 미세 학습 없이도 다양한 문제를 어느 정도는 해결할 수 있다는 것을 발견

The cat couldn't fit into the hat because it was too big.
Does it = the cat or the hat?

$\equiv$ Is $P(\dots\text{because the cat was too big}) \geq$
 $P(\dots\text{because the hat was too big})?$


- 이를 통해 GPT-2는 미세학습 없이 일부 Task에서 SOTA를 달성

	LAMBADA (PPL)	LAMBADA (ACC)	CBT-CN (ACC)	CBT-NE (ACC)	WikiText2 (PPL)
SOTA	99.8	59.23	85.7	82.3	39.14
117M	35.13	45.99	87.65	83.4	29.41
345M	15.60	55.48	92.35	87.1	22.76
762M	10.87	60.12	93.45	88.0	19.93
1542M	8.63	63.24	93.30	89.05	18.34



Zero/Few-Shot In-Context Learning

- Prompt learning: 실제 모델의 훈련없이 프롬프트에서의 입력을 통해 모델을 학습시키는 전략
- In-context learning: 모델이 해야할 작업에 대하여 몇 가지 예제를 입력으로 주고 그 안에서 모델이 해결해야할 작업을 찾도록 훈련






Zero/Few-Shot In-Context Learning

- Zero/One/Few-shot vs. Fine-tuning

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.



Fine-tuning


The model is trained via repeated gradient updates using a large corpus of example tasks.





Zero/Few-Shot In-Context Learning

- 미세학습 없이도 상당한 성능





COT: Chain of Thought

- 프롬프트에 더 많은 정보를 주면 더 잘 함

(a) Few-shot

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A:

(Output) The answer is 8. ✗

(b) Few-shot-CoT

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A:

(Output) The juggler can juggle 16 balls. Half of the balls are golf balls. So there are $16 / 2 = 8$ golf balls. Half of the golf balls are blue. So there are $8 / 2 = 4$ blue golf balls. The answer is 4. ✓

(c) Zero-shot

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?

A: The answer (arabic numerals) is

(Output) 8 ✗

(d) Zero-shot-CoT (Ours)

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?


A: **Let's think step by step.**

(Output) There are 16 balls in total. Half of the balls are golf balls. That means that there are 8 golf balls. Half of the golf balls are blue. That means that there are 4 blue golf balls. ✓



COT: Chain of Thought

- 프롬프트에 더 많은 정보를 주면 더 잘 함





COT: Chain of Thought

- 프롬프트에 더 많은 정보를 주면 더 잘 함

	MultiArith	GSM8K
Zero-Shot	17.7	10.4
Few-Shot (2 samples)	33.7	15.6
Few-Shot (8 samples)	33.8	15.6
Zero-Shot-CoT	78.7	40.7
Few-Shot-CoT (2 samples)	84.8	41.3
Few-Shot-CoT (4 samples : First) (*1)	89.2	-
Few-Shot-CoT (4 samples : Second) (*1)	90.5	-
Few-Shot-CoT (8 samples)	93.0	48.7
Zero-Plus-Few-Shot-CoT (8 samples) (*2)	92.8	51.5
Finetuned GPT-3 175B [Wei et al., 2022]	-	33
Finetuned GPT-3 175B + verifier [Wei et al., 2022]	-	55



COT: Chain of Thought

- 어떤 프롬프트를 주냐에 따라서 성능이 변함

No.	Category	Template	Accuracy
1	instructive	Let's think step by step.	78.7
2		First, (*1)	77.3
3		Let's think about this logically.	74.5
4		Let's solve this problem by splitting it into steps. (*2)	72.2
5		Let's be realistic and think step by step.	70.8
6		Let's think like a detective step by step.	70.3
7		Let's think	57.5
8		Before we dive into the answer,	55.7
9		The answer is after the proof.	45.7
10	misleading	Don't think. Just feel.	18.8
11		Let's think step by step but reach an incorrect answer.	18.7
12		Let's count the number of "a" in the question.	16.7
13		By using the fact that the earth is round,	9.3



Instruction Fine-tuning

- Not aligned

PROMPT *Explain the moon landing to a 6 year old in a few sentences.*

COMPLETION GPT-3

Explain the theory of gravity to a 6 year old.

Explain the theory of relativity to a 6 year old in a few sentences.

Explain the big bang theory to a 6 year old.

Explain evolution to a 6 year old.

- Aligned

PROMPT *Explain the moon landing to a 6 year old in a few sentences.*

COMPLETION **Human**

A giant rocket ship blasted off from Earth carrying astronauts to the moon. The astronauts landed their spaceship on the moon and walked around exploring the lunar surface. Then they returned safely back to Earth, bringing home moon rocks to show everyone.




Instruction Fine-tuning

- 많은 작업에 대하여 학습시켜 어떤 작업이라도 할 수 있게 학습


Step 1: Pretrain (on language modeling)

Lots of text; learn general things!



Step 2: Finetune (on **many tasks**)


~~Not~~ many labels; adapt to the tasks!





Instruction Fine-tuning

- Instruction Fine-tuning (a.k.a pretraining)
 - 대규모로 문제-정답의 쌍을 모으고
 - 프롬프트 학습을 통해 zero/one/few-shot 방식으로 모델을 훈련
 - 다양한 작업을 수행할 수 있는 모델의 훈련
 - 이게 과연 미세학습일까? (많은 데이터와 연산량이 필요)
- **Collect examples** of (instruction, output) pairs across many tasks and finetune an LM





Instruction Fine-tuning

Model input (Disambiguation QA)

Q: In the following sentences, explain the antecedent of the pronoun (which thing the pronoun refers to), or state that it is ambiguous.

Sentence: The reporter and the chef will discuss their favorite dishes.

Options:

- (A) They will discuss the reporter's favorite dishes
- (B) They will discuss the chef's favorite dishes
- (C) Ambiguous

A: Let's think step by step.

Before instruction finetuning

The reporter and the chef will discuss their favorite dishes.

The reporter and the chef will discuss the reporter's favorite dishes.

The reporter and the chef will discuss the chef's favorite dishes.

The reporter and the chef will discuss the reporter's and the chef's favorite dishes.

✗ (doesn't answer question)

Model input (Disambiguation QA)

Q: In the following sentences, explain the antecedent of the pronoun (which thing the pronoun refers to), or state that it is ambiguous.

Sentence: The reporter and the chef will discuss their favorite dishes.

Options:

- (A) They will discuss the reporter's favorite dishes
- (B) They will discuss the chef's favorite dishes
- (C) Ambiguous

A: Let's think step by step.


After instruction finetuning

The reporter and the chef will discuss their favorite dishes does not indicate whose favorite dishes they will discuss. So, the answer is (C). ✓



Instruction Fine-tuning

- Instruction fine-tuning의 한계 or 문제점
 - 대규모의 문제-답 쌍의 데이터를 모으기가 어렵다
 - Open-ended 문제에 대해서는 맞는 답을 정하기가 어렵다
 - 삶과 낭만에 대한 글을 작성해 줘!
 - 모든 토큰의 에러가 같이 평가받지만 몇몇 토큰의 에러는 좀더 큰 문제를 만들 수 있음
- 인간이 좀 더 좋아할 만한 답을 만들고 싶음
 - 하지만 어떻게?





RLHF: Reinforcement Learning from Human Preference

- RLHF: 인간의 선호도를 Reward로 하는 강화학습
- RLHF를 통해 인간이 선호하는 답을 내도록 모델을 훈련
- Human reward $R(s)$

SAN FRANCISCO,
California (CNN) --
A magnitude 4.2
earthquake shook the
San Francisco

...
overturn unstable
objects.

An earthquake hit
San Francisco.
There was minor
property damage,
but no injuries.

$$s_1$$
$$R(s_1) = 8.0$$

The Bay Area has
good weather but is
prone to
earthquakes and
wildfires.



$$s_2$$
$$R(s_2) = 1.2$$

- $R(s)$ 를 최대화하는 s 를 찾자!



RLHF: Reinforcement Learning from Human Preference


- **강화학습 (Reinforcement Learning):** 어떤 환경 안에서 정의된 에이전트가 현재의 상태를 인식하여, 선택 가능한 행동들 중 보상을 최대화하는 행동 혹은 행동 순서를 선택하는 방법
- 딥러닝과 결합되어 사용되어 인간이 해결이 어려운 많은 문제를 해결
 - 바둑, 게임, 단백질 구조 등





RLHF: Reinforcement Learning from Human Preference

- RLHF: 인간의 선호도를 Reward로 하는 강화학습
- RLHF를 통해 인간이 선호하는 답을 내도록 모델을 훈련



- 문제점 1: Human reward를 반복적으로 주는 것은 불가능
- 문제점 2: Human reward는 객관적이지 못하고 수치화가 어려움



RLHF: Reinforcement Learning from Human Preference

- 문제점 1: Human reward를 반복적으로 주는 것은 불가능
 - RL에서 Reward는 각 행동에 대해서 반복적으로 제공해야 하고, 훈련을 위해서는 매우 많이 반복해야 함
- 해결책: 인간의 선호도를 예측하는 독립적인 모델을 지도학습을 통해 만들어 사용

An earthquake hit
San Francisco.
There was minor
property damage,
but no injuries.

$$R(s_1) = 8.0$$


The Bay Area has
good weather but is
prone to
earthquakes and
wildfires.

$$R(s_2) = 1.2$$


Train an LM $RM_\phi(s)$ to
predict human
preferences from an
annotated dataset, then
optimize for RM_ϕ instead.



RLHF: Reinforcement Learning from Human Preference

- 문제점 2: Human reward는 객관적이지 못하고 수치화가 어려움
 - 어떤 답에 대한 reward를 어떻게 정할 것인가?
- 해결법: 상대적 선호도를 측정
- 절대적 보상

An earthquake hit San Francisco.
There was minor property damage,
but no injuries.

>

A 4.2 magnitude earthquake hit San Francisco,
resulting in massive damage.

>

The Bay Area has good weather but is prone to earthquakes and wildfires.

$R(s) = 10$

$R(s) = 4? 5? 6?$

$R(s) = 0$

- 상대적 보상

An earthquake hit San Francisco.
There was minor property damage,
but no injuries.

>

A 4.2 magnitude earthquake hit San Francisco,
resulting in massive damage.


>

The Bay Area has good weather but is prone to earthquakes and wildfires.



RLHF: Reinforcement Learning from Human Preference

- RLHF 는...
 - 사전학습 (+Instructor Finetuning)된 언어 모델을 이용하여
 - 상대적 선호도 방식으로 인간의 선호도를 학습하는 모델을 만들고
 - 이를 이용하여 강화학습 모델을 훈련




- InstructGPT: 다양한 문제에 대하여 RLHF를 수행하여 언어모델을 학습

Step 1

Collect demonstration data and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.




This data is used to fine-tune GPT-3.5 with supervised learning.




Step 2

Collect comparison data and train a reward model.


A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.



Step 3

Optimize a policy against the reward model using the PPO reinforcement learning algorithm.

A new prompt is sampled from the dataset.



The PPO model is initialized from the supervised policy.




The policy generates an output.



The reward model calculates a reward for the output.



The reward is used to update the policy using PPO.



언어모델 학습

보상모델 학습

강화학습

- Labeler 를 통한 데이터의 수집
 - **Plain:** We simply ask the labelers to come up with an arbitrary task, while ensuring the tasks had sufficient diversity.
 - **Few-shot:** We ask the labelers to come up with an instruction, and multiple query/response pairs for that instruction.
 - **User-based:** We had a number of use-cases stated in waitlist applications to the OpenAI API. We asked labelers to come up with prompts corresponding to these use cases.

From these prompts, we produce three different datasets used in our fine-tuning procedure: (1) our SFT dataset, with labeler demonstrations used to train our SFT models, (2) our RM dataset, with labeler rankings of model outputs used to train our RMs, and (3) our PPO dataset, without any human labels, which are used as inputs for RLHF fine-tuning. The SFT dataset contains about 13k training prompts (from the API and labeler-written), the RM dataset has 33k training prompts (from the API and labeler-written), and the PPO dataset has 31k training prompts (only from the API). More details on dataset sizes are provided in Table 6.

Use-case	Prompt
Brainstorming	List five ideas for how to regain enthusiasm for my career
Generation	Write a short story where a bear goes to the beach, makes friends with a seal, and then returns home.



GPT-3 vs. InstructGPT

PROMPT *Explain the moon landing to a 6 year old in a few sentences.*

COMPLETION GPT-3

Explain the theory of gravity to a 6 year old.

Explain the theory of relativity to a 6 year old in a few sentences.

Explain the big bang theory to a 6 year old.

Explain evolution to a 6 year old.

InstructGPT

People went to the moon, and they took pictures of what they saw, and sent them back to the earth so we could all see them.



GPT-3 vs. InstructGPT

PROMPT *Write a short poem about a wise frog.*

COMPLETION GPT-3

Write a short story in which a character has two different names.

Write a short story in which you try to get something back that you have lost.

Write a short story in which a character has a bad dream.

InstructGPT

The frog is a symbol of wisdom
He knows all the secrets of the world
He is a master of disguise
And a great teacher of life
He is a symbol of transformation
And the bringer of change
He is the frog who has seen it all
And knows the meaning of it all

- ChatGPT: Instruction Fine-tuning + RLHF

ChatGPT: Optimizing Language Models for Dialogue

Note: OpenAI (and similar companies) are keeping more details secret about ChatGPT training (including data, training parameters, model size)—perhaps to keep a competitive edge...

Methods

We trained this model using Reinforcement Learning from Human Feedback (RLHF), using the same methods as InstructGPT, but with slight differences in the data collection setup. We trained an initial model using supervised fine-tuning: human AI trainers provided conversations in which they played both sides—the user and an AI assistant. We gave the trainers access to model-written suggestions to help them compose their responses. We mixed this new dialogue dataset with the InstructGPT dataset, which we transformed into a dialogue format.



Multimodal GenAI: 시각+언어+청각 등

MI

My 5 year old keeps talking about a "super-duper sunflower hedgehog" -- what does it look like?



Multimodal GenAI: 시각+언어+청각 등

RE REECE



What is this

CHATGPT

The item in the images is a TP-Link smart plug. It's an electronic device that allows you to turn a traditional outlet into a smart one, enabling you to control plugged-in devices remotely via a smartphone app or through voice commands with smart assistants like Amazon Alexa or Google Assistant. The button on the side is typically used for manual control and setup.



Message



AInterestingUpdate ✓
@ainterestingupdate

Helping the blind to see!
New version of ChatGPT helps a blind man navigate the city



감사합니다